Eksplorasi Data Ulasan Penumpang Cathay Pacific: Anotasi Sentimen, Distribusi Rating, dan Pembuatan Judul Otomatis

Dosen : Dr. Puji Catur Siswi Praptini, ST., MTI

Nama Kelompok :

1. *Amanda Damayanti (202432027)*
2. *Khoirun Nisak (202432028)*
3. *Jaquinta Rahmadias (202432001)*
4. *Petique Bulan Nanindah(202432046)*
5. *Najwa Nadhira (202432033)*
6. *Muhammad Nabil Virzatullah (202432062)*

INSTITUT TEKNOLOGI PLN

FAKULTAS TELEMATIKA ENERGI

SISTEM INFORMASI

2025/2026

Abstrak

Ulasan pelanggan merupakan sumber data opini yang kaya dan memuat informasi nyata tentang kualitas produk maupun layanan. Masalahnya, ulasan tersebut kerap terlalu panjang, berulang, atau menyembunyikan inti pesan di balik terlalu banyak detail. Sistem peringkasan opini hadir untuk mengekstrak informasi yang relevan, namun sering mengalami penurunan performa ketika model dilatih pada satu domain lalu digunakan di domain lain. Makalah ini menyajikan dataset yang dibangun dari ulasan penumpang Cathay Pacific yang dikumpulkan melalui web scraping dari portal Skytrax. Paket ini terdiri dari dua dataset teranotasi: review_titles_data yang memasangkan 1.500 ulasan dengan judulnya dan skor polaritas sentimen, serta annotated_sentiment_dataset yang memuat ulasan yang sama dengan label rating, nilai rekomendasi, dan kelas sentimen. Kedua dataset ini ditujukan untuk pelatihan model Natural Language Processing (NLP) secara terbimbing pada tugas peringkasan abstraktif, pembuatan judul, dan klasifikasi sentimen.

Kata Kunci: Peringkasan abstraktif, Klasifikasi sentimen, Ulasan maskapai penerbangan, Web scraping, Cathay Pacific, Model bahasa terlatih, Adaptasi domain

Specification Table

Subjek	Artificial Intelligence, Data Science
Area subjek spesifik	Natural Language Processing: Peringkasan Abstraktif dan Analisis Sentimen pada Ulasan Maskapai Cathay Pacific
Jenis data	Teks, Tabel
Cara perolehan data	Data ulasan dikumpulkan dari situs Skytrax (www.airlinequlity.com) melalui web scraping menggunakan bahasa pemrograman Python pada platform Google Colaboratory.
Format data	Raw (mentah) Labeled (berlabel) Analyzed(teranalisis)
Deskripsi pengumpulan data	Data primer dikumpulkan dengan menentukan URL dari berbagai halaman ulasan maskapai Cathay Pacific, lalu mengekstrak elemen yang dibutuhkan seperti review, title, rating, dan recommended menggunakan library Python 'requests' dan 'beautifulsoup'. Dataset yang terkumpul diperiksa untuk duplikasi dan nilai yang hilang. Ulasan dengan judul atau elemen yang hilang dihapus dari dataset. Untuk review_titles_data, review dan title diambil langsung dari website beserta perhitungan polaritas sentimen menggunakan TextBlob. Untuk annotated_sentiment_dataset, review, title, rating, dan recommended diambil dari website, sementara nilai sentiment ditetapkan berdasarkan nilai rating pelanggan.
Lokasi sumber data	Skytrax https://www.airlinequality.com/
Aksesibilitas data	Reposiotory: Google Drive Direct URL to data : https://drive.google.com/drive/folders/1lUP2izXff9XQl_T2aUQcsX3b1zART2zs?usp=sharing

Pendahuluan

Penumpang maskapai cukup banyak meninggalkan ulasan setelah penerbangan. Mereka menuliskan pengalaman secara rinci, mulai dari hal yang berjalan baik, yang bermasalah, hingga hal yang ingin mereka ubah. Secara kolektif, ulasan-ulasan ini membentuk sumber data yang informatif namun sulit dikelola. Sebuah ulasan yang mencapai ratusan kata mengandung jauh lebih banyak gangguan daripada informasi inti, dan membaca ribuan ulasan secara manual bukan pendekatan yang realistis bagi peneliti maupun tim layanan.

Peringkasan abstraktif menjawab tantangan ini secara langsung. Tidak seperti pendekatan ekstraktif yang menyalin kalimat dari teks sumber, model abstraktif menghasilkan teks baru yang menangkap inti ulasan sebagaimana manusia menulisnya. Persoalannya, model-model ini membutuhkan data latih berlabel, dan dataset yang tersedia selama ini berasal dari domain umum seperti berita atau ulasan produk. Ketika model yang dilatih pada domain tersebut dihadapkan pada konten penerbangan, performanya cenderung menurun. Inilah yang disebut masalah domain shift, dan dataset yang dibuat khusus untuk domain tertentu memiliki nilai yang nyata dalam mengatasi masalah ini.

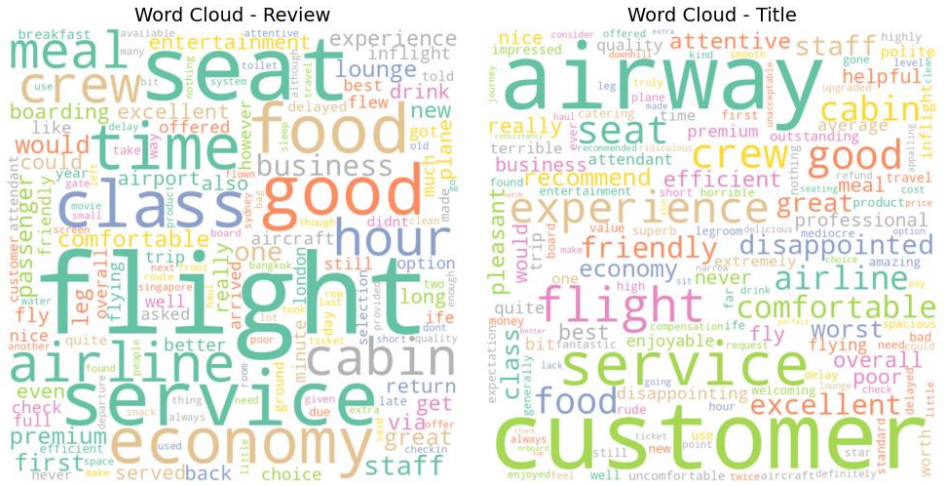
Klasifikasi sentimen adalah tugas lain yang didukung oleh dataset ini. Mengetahui apakah sebuah ulasan bersifat positif, negatif, atau netral penting untuk analisis tren, perbaikan layanan, dan pengarahan umpan balik ke tim yang tepat. Anotasi berbasis rating adalah cara praktis untuk menetapkan label-label tersebut tanpa harus meninjau setiap entri secara manual.

Makalah ini mendeskripsikan dataset yang dikumpulkan dari ulasan maskapai Cathay Pacific di portal Skytrax. Paket ini berisi 1.500 ulasan yang disiapkan untuk dua tugas: pembuatan judul disertai analisis polaritas sentimen, serta klasifikasi sentimen berbasis rating. Tujuannya adalah menyediakan sumber daya yang bersih, teranotasi, dan spesifik terhadap domain, sehingga peneliti NLP tidak perlu memulai dari nol.

1. Deskripsi Data

Dataset ini berisi dua dataset: review_titles_data dan annotated_sentiment_dataset. Keduanya berasal dari kumpulan ulasan pelanggan Cathay Pacific yang sama, diproses melalui pipeline preprocessing yang serupa, lalu dipisahkan berdasarkan tujuan penggunaannya.

Dataset review_titles_data memasangkan setiap ulasan dengan judul asli yang ditulis pelanggan serta skor polaritas sentimen yang dihitung secara otomatis. Dataset ini dirancang untuk tugas pembuatan judul dan peringkasan abstraktif. Sementara itu, annotated_sentiment_dataset menambahkan label terstruktur berupa rating, rekomendasi, dan kelas sentimen, sehingga cocok digunakan untuk tugas klasifikasi.



Gambar 1. *Word cloud yang dihasilkan dari dataset ulasan dan judul maskapai Cathay Pacific*

Gambar 1 menunjukkan kata-kata yang paling sering muncul pada ulasan dan judul setelah preprocessing. Pada word cloud ulasan, kata-kata seperti ‘flight’, ‘service’, ‘seat’, ‘cabin’, dan ‘airline’ mendominasi, mencerminkan topik utama yang ditulis pelanggan. Word cloud judul menunjukkan pola serupa namun dengan lebih banyak bahasa evaluatif: kata seperti ‘airway’, ‘customer’, ‘experience’, ‘disappointed’, dan ‘recommend’ tampak menonjol, yang masuk akal mengingat judul cenderung lebih langsung menyampaikan penilaian.

Word Cloud dibentuk dari seluruh teks ulasan Cathay Pacific setelah melalui tahap preprocessing. Ukuran kata menunjukkan frekuensi kemunculan dalam dataset, sehingga semakin besar ukuran kata maka semakin sering kata tersebut muncul pada ulasan.

1) Flight (flight) menjadi topik yang paling sering dibahas dalam ulasan pelanggan.
2) Pelanggan banyak menyoroti layanan (service), awak kabin (crew), dan kenyamanan kursi (seat).
3) Makanan (food, meal) dan fasilitas penerbangan juga sering menjadi perhatian pelanggan.
4) Terdapat pembahasan mengenai pengalaman pada kelas Business (business class) dan Economy (economy class).
5) Fokus utama ulasan berkaitan dengan kualitas layanan (service quality) dan pengalaman perjalanan (flight experience).

2. Dataset Review_Titles_Data

Dataset review_titles_data memiliki 1.500 baris dan lima kolom: ‘Title’, ‘Review’, ‘title_clean’, ‘review_clean’, dan ‘polarity’. Kolom ‘Title’ dan ‘Review’ berisi teks asli

sebagaimana ditulis oleh pelanggan. Kolom ‘title_clean’ dan ‘review_clean’ menyimpan versi yang telah diproses, dengan tanda baca dihapus, teks diubah ke huruf kecil, dan stop word disaring. Kolom ‘polarity’ berisi skor sentimen berupa angka desimal yang dihitung menggunakan TextBlob, dengan rentang dari -1,0 (paling negatif) hingga 1,0 (paling positif).

Tabel 1. *Sampel data dari dataset review_titles_data*

Judul	Ulasan
"No option for a cash refund"	Saya baru-baru ini melakukan perjalanan dengan Cathay Pacific dari Hyderabad ke Toronto melalui Hong Kong. Sayangnya, pengalaman saya sangat mengecewakan. Kedua segmen perjalanan saya dijadwalkan ulang secara mendadak tanpa pemberitahuan sebelumnya.

Gambar 2 menunjukkan distribusi karakter pada ulasan dan judul. Sebagian besar ulasan berada di antara 200 hingga 1.000 karakter, dengan beberapa yang melampaui 3.000 karakter. Judul jauh lebih pendek dan konsisten, dengan distribusi yang mengelompok antara 20 hingga 45 karakter. Variasi panjang ulasan mencerminkan kebebasan pelanggan dalam menulis: ada yang hanya meninggalkan satu kalimat, ada pula yang menyusun beberapa paragraf.

Visualisasi pada **Gambar 2** juga menunjukkan sebaran jumlah karakter secara terpisah antara isi ulasan (Reviews) dan judul ulasan (Titles).

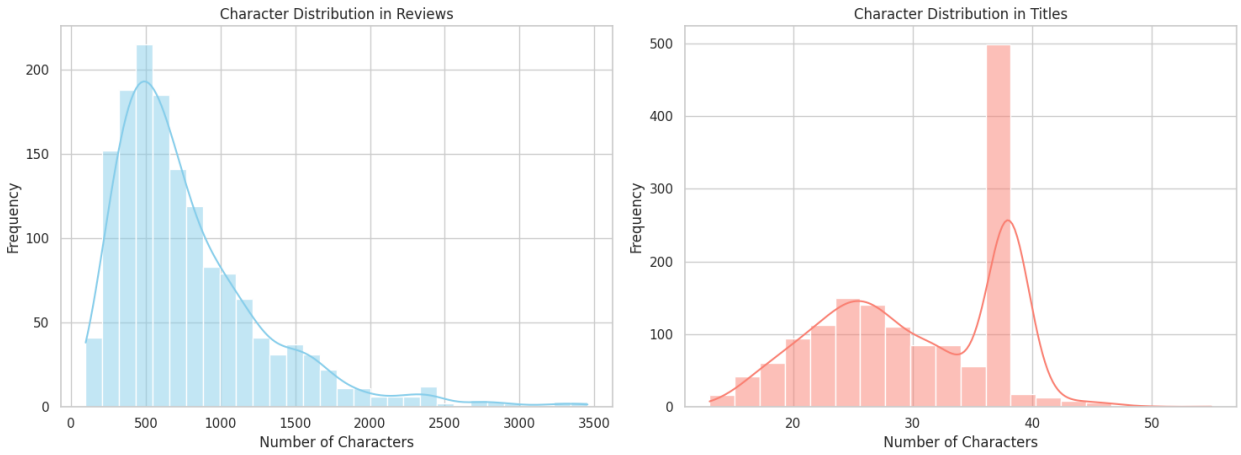
Character Distribution in Reviews (Sisi Kiri - Biru Muda):

1) Bentuk Distribusi: Grafik menunjukkan pola distribusi yang condong ke kanan (Right-Skewed / Positively Skewed Distribution). Puncak frekuensi tertinggi (mode) berada pada rentang 400 hingga 600 karakter. Setelah melewati puncak tersebut, frekuensi menurun secara bertahap hingga di atas 3000 karakter.
2) Interpretasi Analisis: Mayoritas penumpang Cathay Pacific cenderung menulis umpan balik dengan panjang teks yang ringkas hingga sedang (300-800 karakter). Namun, adanya ekor grafik yang memanjang ke sisi kanan (long-tail) menandakan adanya sebagian kecil pengguna yang menulis teks sangat panjang (2000-3500 karakter). Teks yang sangat panjang ini biasanya mengindikasikan ulasan berupa kronologi komplain yang mendetail atau laporan perjalanan menyeluruh.

Character Distribution in Titles (Sisi Kanan - Merah Muda):

1) Bentuk Distribusi: Grafik sebaran karakter pada judul menunjukkan bentuk yang unik dengan lonjakan frekuensi ekstrem yang sangat tinggi (spike) pada rentang 36 hingga 38 karakter, di mana frekuensinya mendekati angka 500. Di luar lonjakan tersebut, sebaran data membentuk kurva normal landai pada rentang 15 hingga 35 karakter.
2) Interpretasi Analisis: Lonjakan tajam di area 36-38 karakter ini mengindikasikan adanya kecenderungan standarisasi, pembatasan sistematis (misalnya batas karakter input judul

ulasan dari platform sumber data), atau penggunaan frasa templat yang berulang oleh banyak penumpang saat menuliskan judul ulasan.



Gambar 2. *Distribusi karakter pada ulasan dan judul dalam dataset review_titles_data.*

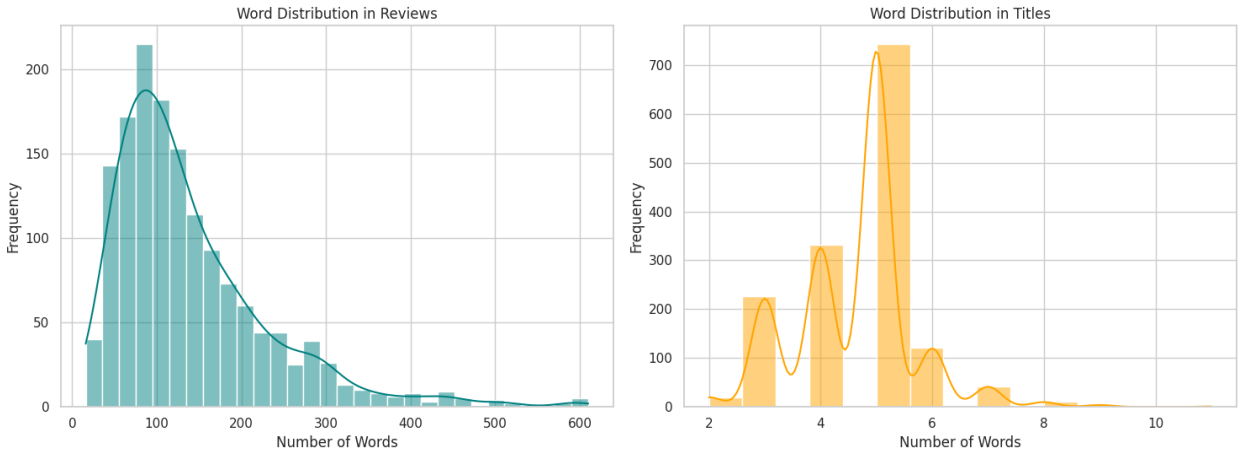
Gambar 3 mengilustrasikan distribusi jumlah kata di mana memaparkan sebaran jumlah kata (Word Distribution) untuk mengonfirmasi karakteristik struktural dari dataset teks yang dianalisis.

Word Distribution in Reviews (Sisi Kiri - Hijau Toska):

1) Bentuk Distribusi: Pola grafik ini sangat selaras dengan grafik distribusi karakter ulasan pada Gambar 2, yaitu membentuk kurva Right-Skewed. Konsentrasi data terbesar berada pada rentang 70 hingga 110 kata per ulasan. Frekuensi tertinggi tercatat di atas nilai 200 untuk ulasan dengan panjang sekitar 90 kata.
2) Interpretasi Analisis: Keselarasan antara distribusi kata dan karakter menunjukkan adanya korelasi linear yang kuat. Rentang 70-110 kata dianggap sebagai batas ideal bagi penumpang untuk menyampaikan opini mereka secara padat, jelas, dan mencakup informasi inti penerbangan (seperti kenyamanan, layanan kru, atau ketepatan waktu).

Word Distribution in Titles (Sisi Kanan - Jingga):

1) Bentuk Distribusi: Berbeda dengan visualisasi kata pada isi ulasan, distribusi kata pada judul memiliki sifat multimodal diskret. Lonjakan frekuensi terbesar secara masif terjadi tepat pada angka 5 kata, dengan frekuensi melampaui 700 data. Terdapat pula sub-puncak pada angka 4 kata dan 3 kata. Judul ulasan hampir tidak ada yang melebihi 8 kata.
2) Interpretasi Analisis: Penumpang sangat menyukai judul yang singkat, padat, dan bertindak sebagai kesimpulan utama (punchline). Judul yang terdiri atas 4 sampai 5 kata merupakan format penulisan paling populer. Informasi ini sangat berguna untuk proses Feature Engineering ke depan, di mana batas atas token (padding length) untuk judul cukup diset pada nilai maksimum 10-12 kata saja.



Gambar 3. *Distribusi kata pada ulasan dan judul dalam dataset review_titles_data*

3. Dataset Annotated_Sentiment

Dataset annotated_sentiment_dataset memiliki 1.500 baris dan lima kolom: ‘review’, ‘title’, ‘rating’, ‘recommended’, dan ‘sentiment’. Kolom ‘review’ berisi teks ulasan lengkap dari pelanggan. Kolom ‘title’ menyimpan judul ulasan. Kolom ‘rating’ menunjukkan skor keseluruhan yang diberikan pelanggan pada skala 1 (terburuk) hingga 10 (terbaik). Kolom ‘recommended’ merupakan nilai biner yang menunjukkan apakah pengulas merekomendasikan maskapai tersebut, di mana 1 berarti ya dan 0 berarti tidak. Kolom sentiment adalah label anotasi yang diturunkan dari nilai rating.

Sentimen ditetapkan menggunakan aturan pemetaan tetap: rating 1 hingga 4 diberi label 0 (negatif), rating 5 hingga 6 diberi label 1 (netral), dan rating 7 hingga 10 diberi label 2 (positif). Pendekatan ini mengikuti metode anotasi yang digunakan pada dataset ulasan maskapai serupa dan memungkinkan kolom sentimen digunakan sebagai label ground-truth untuk model klasifikasi tanpa memerlukan anotasi manual pada setiap entri.

Tabel 2. *Sampel data dari annotated_sentiment_dataset.*

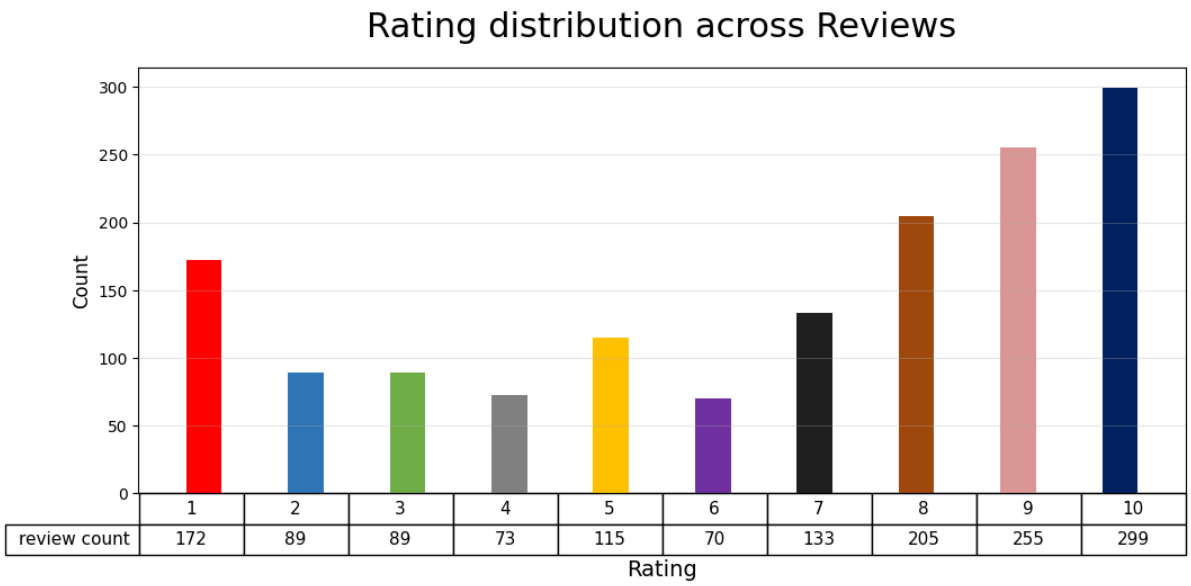
Ulasan	Judul	Rating	Direkomendasikan	Sentimen
Saya baru-baru ini melakukan perjalanan dengan Cathay Pacific dari Hyderabad ke Toronto... Tidak ada opsi pengembalian dana tunai yang diberikan meski sudah diminta.	"No option for a cash refund"	1	0	0
Kelas Bisnis yang biasa saja, dengan makanan maskapai yang standar. Staf cukup menyenangkan. Pesawat sudah tua dan terasa lelah. Kelas Bisnis tidak sebanding dengan harganya untuk rute pendek ini.	"Aircraft old and tired"	5	0	1

Aria Suite kelas bisnis sangat luar biasa. Layanan cepat dan penuh perhatian. Kabin terasa hangat dan elegan. Makanan sangat baik dan layanan dalam penerbangan sungguh memuaskan.	"Cathay Pacific has nailed it"	10	1	2

Tabel 3. *Statistik annotated_sentiment_dataset.*

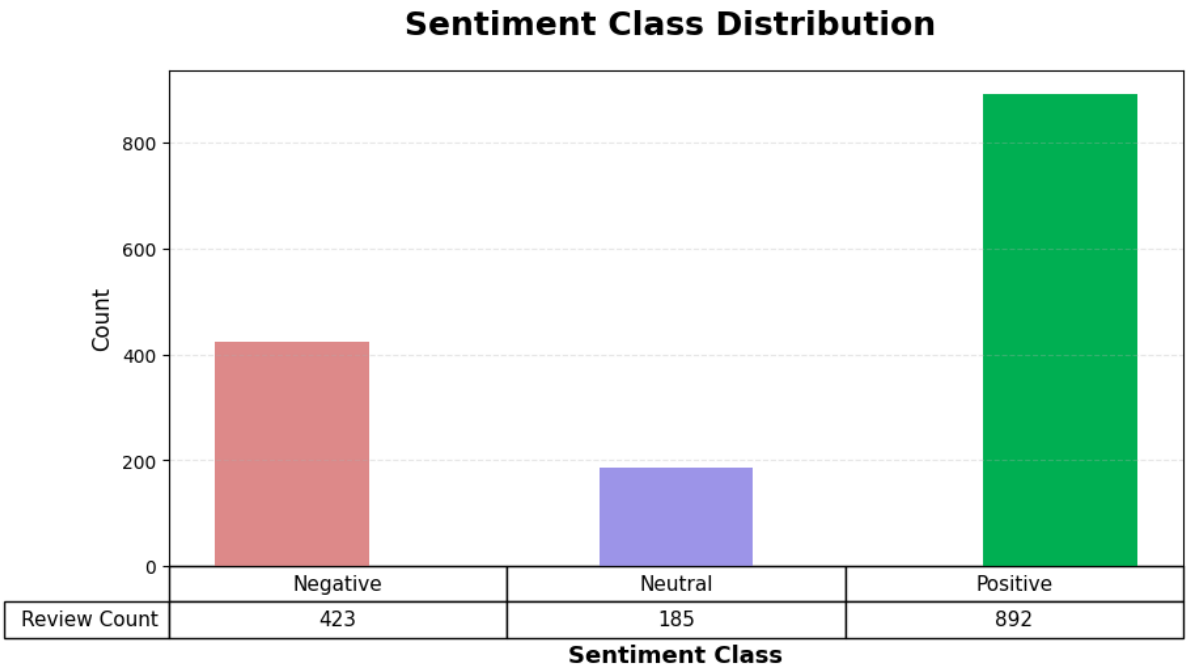
Total Ulasan	Negatif (0)	Netral (1)	Positif (2)
1.500	423	185	892

Gambar 4 menunjukkan distribusi rating pelanggan di seluruh dataset. Rating 1, 9, dan 10 adalah yang paling banyak muncul, masing-masing dengan 172, 255, dan 299 ulasan. Pola bimodal ini umum ditemukan pada ulasan daring, di mana pelanggan dengan pengalaman sangat buruk atau sangat baik lebih cenderung menulis ulasan dibandingkan mereka yang merasa biasa saja.



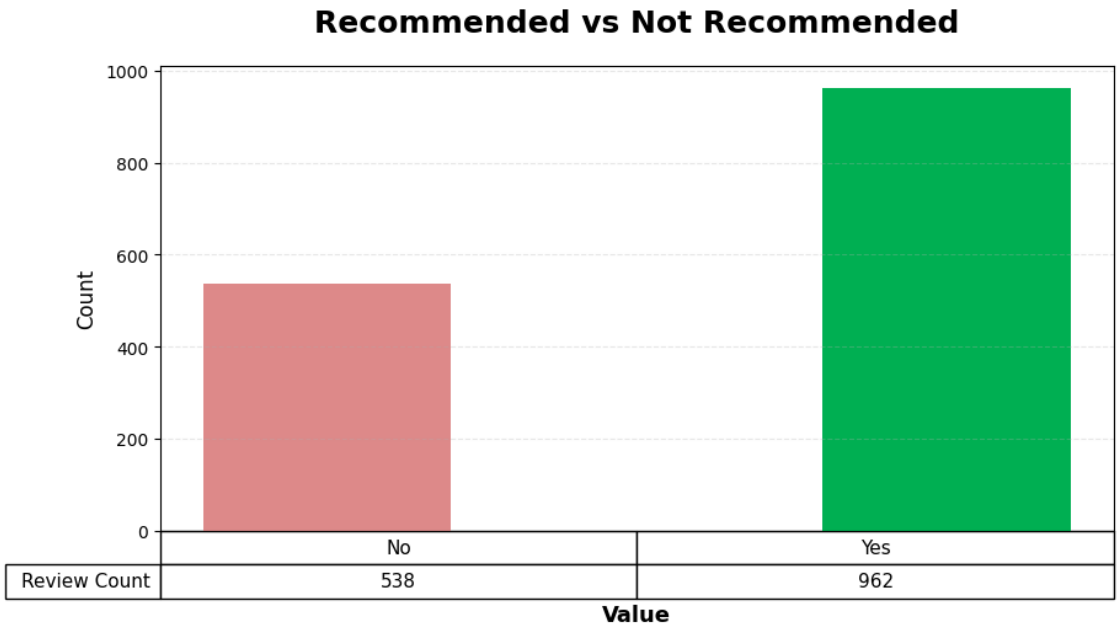
Gambar 4. *Distribusi rating pelanggan pada ulasan dalam annotated_sentiment_dataset.*

Gambar 5 menyajikan distribusi kelas sentimen. Ulasan positif berjumlah 892 entri, negatif 423, dan netral 185. Dominasi sentimen positif pada dataset Cathay Pacific ini sejalan dengan reputasi maskapai yang secara historis mendapat peringkat baik dalam survei internasional. Meski demikian, volume ulasan negatif cukup besar sehingga kedua sisi spektrum tetap berguna untuk pelatihan model.



***Gambar 5**. Distribusi kelas sentimen pada ulasan dalam annotated_sentiment_dataset.*

Gambar 6 menampilkan pembagian rekomendasi. Dari 1.500 ulasan, sebanyak 962 pelanggan (64,1%) merekomendasikan Cathay Pacific dan 538 (35,9%) tidak merekomendasikan. Distribusi ini secara umum selaras dengan keseimbangan kelas sentimen, yang wajar karena rekomendasi dan sentimen sama-sama diturunkan dari rating yang sama.



***Gambar 6.** Distribusi rekomendasi pelanggan pada ulasan dalam annotated_sentiment_dataset.*

4. Desain Eksperimen, Bahan, dan Metode

5.1. Pengumpulan Data

Ulasan dikumpulkan dari portal ulasan maskapai Skytrax (www.airlinequality.com) menggunakan Web Scraper Extension pada browser untuk mengekstraksi data utama dari halaman ulasan Cathay Pacific. Proses ini menghasilkan data awal yang mencakup beberapa atribut penting, seperti judul ulasan, isi ulasan, rating keseluruhan, serta informasi rekomendasi pelanggan. Selanjutnya, dilakukan penyempurnaan data menggunakan Python melalui proses scraping berbasis API/HTTP request untuk melengkapi beberapa kolom yang belum berhasil diekstraksi secara optimal oleh Web Scraper Extension. Data hasil penggabungan kemudian dibersihkan, divalidasi, dan disimpan dalam format XLSX sebagai dataset yang siap digunakan pada tahap preprocessing dan analisis sentimen.

Dataset yang terkumpul berisi 1.500 ulasan yang mencakup berbagai rute penerbangan dan kelas kabin. Ulasan mencakup beberapa tahun, dengan entri terbaru mencerminkan kondisi layanan maskapai pasca-pandemi. Dataset yang telah terkumpul selanjutnya digunakan sebagai sumber data utama pada proses preprocessing, analisis sentimen, dan visualisasi hasil penelitian.

5.2. Preprocessing

Teks ulasan mentah memerlukan pembersihan sebelum dapat digunakan. Pipeline preprocessing menangani langkah-langkah berikut: penghapusan tag verifikasi perjalanan (misalnya "Trip Verified "), pengubahan teks ke huruf kecil, penghapusan tanda baca, tokenisasi, penghapusan stop word menggunakan daftar stop word bahasa Inggris dari NLTK, serta lemmatization untuk mengubah kata ke bentuk dasarnya. Hasil preprocessing kemudian digabung kembali menjadi teks bersih yang siap dianalisis.

Polaritas sentimen dihitung menggunakan penganalisis berbasis pola dari TextBlob, yang menghasilkan nilai desimal antara -1,0 hingga 1,0 pada setiap ulasan. Rata-rata polaritas di seluruh 1.500 ulasan dalam dataset adalah 0,176, yang menunjukkan kecenderungan positif yang moderat secara keseluruhan.

5.3. Anotasi Data

Label kelas sentimen dihasilkan dari rating yang diberikan pelanggan menggunakan aturan pemetaan tetap. Rating 1 hingga 4 diberi kelas sentimen 0 (negatif), rating 5 hingga 6 diberi kelas 1 (netral), dan rating 7 hingga 10 diberi kelas 2 (positif). Kolom recommended dari data mentah dikonversi dari string ya/tidak menjadi bilangan bulat biner (1 untuk ya, 0 untuk tidak). Tidak ada anotasi manual yang dilakukan pada masing-masing ulasan.

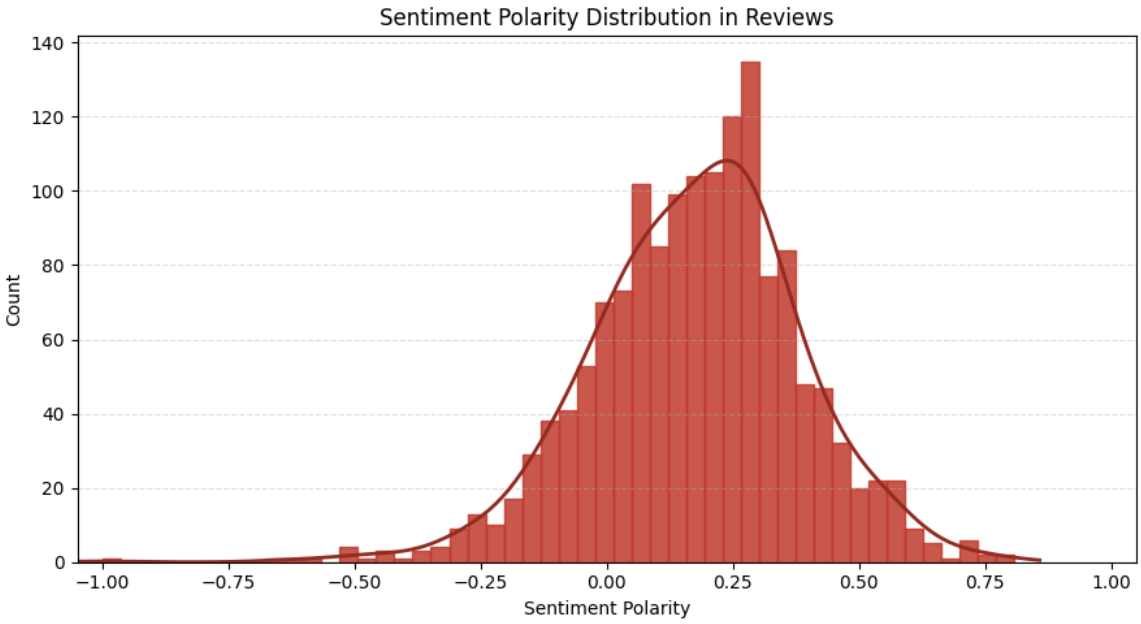
Tabel 4. *Skala rating untuk anotasi kelas sentimen.*

Rating	Kelas Sentimen
1–4	Negatif (0)
5–6	Netral (1)
7–10	Positif (2)

5. Analisis Data

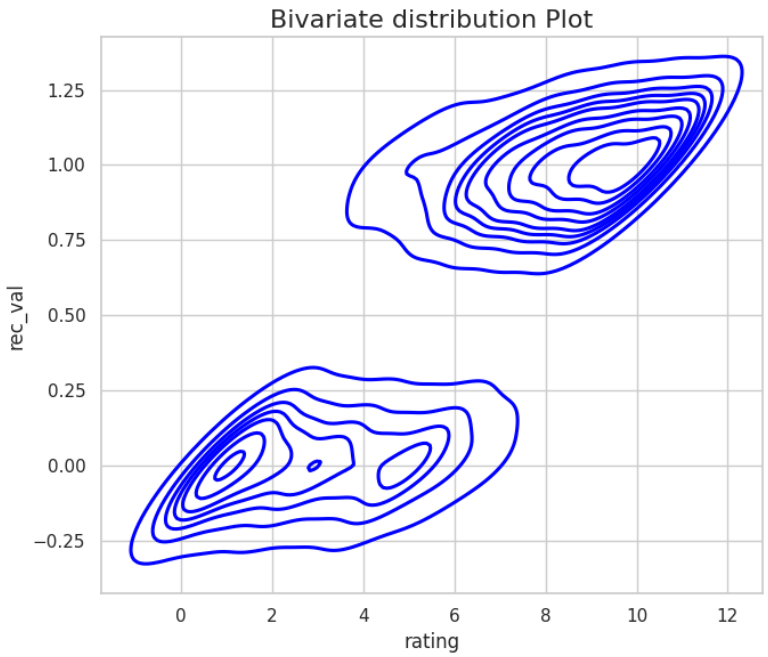
Gambar 7 menunjukkan kecenderungan sentimen pelanggan terhadap Cathay Pacific (positif, netral, atau negatif), dengan tujuan melihat sebaran nilai sentimen dari seluruh review setelah dihitung menggunakan TextBlob. Nilai polarity berkisar dari -1 (sangat negatif), 0 (netral), hingga +1 (sangat positif). Dari grafik terlihat bahwa mayoritas review berada pada rentang 0 sampai 0,4, dengan puncak distribusi sekitar 0,2–0,3. Sangat sedikit review yang memiliki polarity negatif (< 0), sementara sebagian review memiliki polarity tinggi (> 0,5). Artinya, sebagian besar pelanggan memberikan ulasan dengan sentimen positif terhadap layanan Cathay Pacific. Garis lengkung pada grafik merupakan Kernel Density Estimation (KDE), yaitu estimasi kepadatan distribusi data yang digunakan untuk memperlihatkan pola sebaran sentimen secara lebih halus dibandingkan histogram biasa.

Nilai polarity ini dihasilkan dari TextBlob().sentiment.polarity, yang bekerja dengan pendekatan lexicon-based, yaitu mencocokkan kata dengan kamus skor sentimen bernama pattern.en yang sudah berisi ribuan kata bahasa Inggris beserta nilai polaritasnya (-1,0 sampai +1,0). Saat menerima sebuah kalimat, TextBlob memecahnya menjadi kata-kata, mencari skor tiap kata di kamus tersebut, lalu menggabungkan dan merata-ratakan seluruh skor yang ditemukan untuk menghasilkan nilai akhir antara -1 sampai +1. Sebagai contoh, pada kalimat "The crew was excellent and the seat was comfortable", kata "excellent" memiliki skor +1,0 dan "comfortable" +0,5, sehingga rata-ratanya menghasilkan polarity 0,75 (positif). Yang perlu diingat, TextBlob tidak benar-benar "memahami" makna kalimat seperti manusia, ia hanya mencocokkan kata per kata dengan database yang sudah ditentukan sebelumnya, sehingga bisa saja salah membaca sarkasme atau kalimat dengan konteks ambigu.



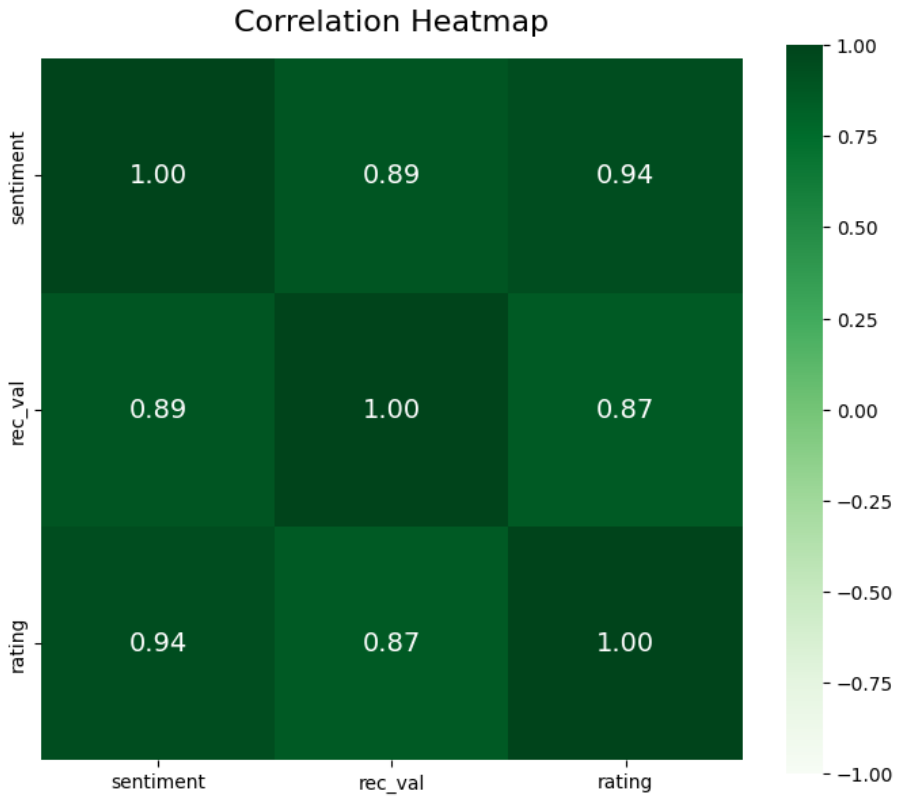
***Gambar** 7. Distribusi polaritas sentimen pada ulasan dalam dataset review_titles_data.*

Gambar 8 menunjukkan hubungan antara rating pelanggan dan nilai rekomendasi (rec_val). Terlihat bahwa pelanggan dengan rating tinggi cenderung memberikan rekomendasi, sedangkan pelanggan dengan rating rendah cenderung tidak merekomendasikan layanan. Pola kontur yang membentuk arah diagonal ke atas menunjukkan adanya hubungan positif antara kedua variabel, di mana semakin tinggi rating yang diberikan, semakin besar kemungkinan pelanggan merekomendasikan layanan Cathay Pacific.



Gambar 8. *Plot distribusi probabilitas bersama dari rating pelanggan dan nilai rekomendasi.*

Gambar 9 menunjukkan korelasi positif yang kuat antara sentiment, rating, dan recommendation value. Nilai korelasi tertinggi terdapat pada sentiment dan rating (0.94), diikuti oleh sentiment dan recommendation (0.89), serta rating dan recommendation (0.87). Hasil ini menunjukkan bahwa pelanggan dengan rating tinggi cenderung memiliki sentimen positif dan lebih bersedia merekomendasikan layanan Cathay Pacific. Secara keseluruhan, ketiga variabel memiliki hubungan yang kuat dalam menggambarkan tingkat kepuasan pelanggan.



***Gambar 9**. Heatmap korelasi — rating pelanggan, rekomendasi, dan sentimen*

6. Hasil Diskusi

Beberapa dataset ulasan maskapai yang di-scrape dari Skytrax dan platform serupa sudah tersedia secara publik. Dataset ini berbeda dari yang sudah ada dalam beberapa hal.

Pertama, data ini bersifat terkini. Sebagian besar dataset yang ada dikumpulkan beberapa tahun lalu dan tidak mencerminkan pola layanan pasca-pandemi. Cathay Pacific mengalami perubahan operasional yang signifikan antara tahun 2020 dan 2024, dan ulasan dari periode tersebut mencerminkan pengalaman pelanggan yang berbeda dari data sebelum pandemi.

Kedua, sebagian besar dataset publik hanya berisi field mentah hasil scraping tanpa anotasi NLP yang spesifik terhadap domain. Dataset ini menambahkan kolom berlabel untuk peringkasan abstraktif (judul sebagai target) dan klasifikasi sentimen (kolom sentimen yang diturunkan dari rating), yang umumnya tidak tersedia dalam dataset hasil scraping biasa. Peneliti yang mengerjakan tugas peringkasan atau klasifikasi biasanya harus membangun lapisan anotasi ini sendiri.

Ketiga, dataset ini berfokus pada satu maskapai. Kualitas layanan maskapai bervariasi secara signifikan antar maskapai, rute, dan kelas kabin. Dataset yang mencampurkan beberapa maskapai sekaligus menghadirkan noise yang belum tentu berguna ketika pertanyaan penelitian

bersifat spesifik terhadap satu maskapai. Fokus pada Cathay Pacific membuat domain cukup sempit untuk fine-tuning yang terarah.

7. Pernyataan Etika

Data dikumpulkan dari portal ulasan maskapai Skytrax semata-mata untuk keperluan penelitian akademik. Seluruh ulasan di platform tersebut dapat diakses secara publik. Tidak ada informasi identitas pribadi di luar apa yang secara sukarela ditulis pelanggan dalam ulasan publik yang dikumpulkan atau disimpan. Dataset tidak mencakup informasi akun pengulas, alamat surel, maupun detail kontak lainnya.

Referensi

Syed, A. A., Gaol, F. L., Boediman, A., Matsuo, T., & Budiharto, W. (2023). A data package for abstractive opinion summarization, title generation, and rating-based sentiment prediction for airline reviews. *Data in Brief*, *50*, 109535.

Bird, S., Klein, E., & Loper, E. (2009). *Natural language processing with Python: analyzing text with the natural language toolkit*. " O'Reilly Media, Inc.".

https://www.airlinequality.com/